Clustering — Documentation Machine Learning

1. Qu'est-ce que le Clustering ?

Le **Clustering** est une technique d'**apprentissage non supervisé** (*Unsupervised Learning*).

Contrairement à la classification ou à la régression, on ne dispose pas d'une variable cible `y`.

On possède uniquement des observations `X` et on cherche à découvrir automatiquement des **groupes naturels** dans les données.

Objectif

Créer des groupes appelés **clusters** tels que :

- les observations d'un même cluster soient **similaires** ;
- les observations de clusters différents soient **différentes**.

On cherche donc à obtenir :

- **Forte similarité intra-cluster** : les individus du même groupe se ressemblent.
- **Forte différence inter-clusters** : les groupes sont suffisamment distincts.

2. Le rôle des distances

La majorité des algorithmes de clustering utilisent une notion de **distance ou de similarité**.

L'idée est simple :

> Plus deux observations sont proches, plus elles sont considérées comme similaires.

Distance Euclidienne

C'est l'une des distances les plus utilisées.

$$d(x, y) = \sqrt{\Sigma (x_i - y_i)^2} \quad \text{pour } i = 1 \text{ à } n$$

Pour deux points en 2 dimensions :

$$d = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$

Distance de Manhattan

Aussi appelée distance **L1** :

$$d(x, y) = \Sigma \, |x_i - y_i| \quad \text{pour } i = 1 \text{ à } n$$

Similarité cosinus

Elle mesure principalement l'**orientation** de deux vecteurs plutôt que leur distance.

Elle est souvent utilisée en traitement du texte (TF-IDF, embeddings).

4. Pourquoi le Scaling est important ?

Les algorithmes basés sur les distances peuvent être fortement influencés par l'échelle des variables.

Par exemple, une variable exprimée en milliers (salaire) dominera une variable exprimée en unités (âge) si l'on ne normalise pas.

Solutions courantes :

- **StandardScaler** : centre et réduit (moyenne 0, écart-type 1).
- **MinMaxScaler** : ramène les valeurs entre 0 et 1.
- **RobustScaler** : utilise la médiane et l'IQR, résistant aux outliers.

> Règle générale : **toujours scaler avant K-Means, DBSCAN ou un clustering hiérarchique basé sur des distances euclidiennes.**

6. Les principaux algorithmes de Clustering

Les trois algorithmes à connaître sont :

1. **K-Means**
2. **Clustering hiérarchique**
3. **DBSCAN**

🔵 7. K-Means

Définition

K-Means est un algorithme de clustering basé sur les **centroïdes**.

Il cherche à diviser les données en `K` groupes.

`K` représente le nombre de clusters souhaités.

Exemple :

```
K = 3
```

Le modèle va créer :

```
Cluster 0
Cluster 1
Cluster 2
```

⚙️ Fonctionnement

Étape 1 — Choisir K

On choisit le nombre de clusters.

Étape 2 — Initialiser les centroïdes

L'algorithme positionne initialement `K` centroïdes.

Étape 3 — Affecter les observations

Chaque observation est affectée au **centroïde le plus proche**.

Étape 4 — Recalculer les centroïdes

Pour chaque cluster, on calcule la moyenne des observations.

Cette moyenne devient le nouveau centroïde.

🎯 8. Fonction objectif de K-Means

K-Means cherche à minimiser la distance entre les observations et leur centroïde.

Cette quantité est appelée **inertie** ou **Within-Cluster Sum of Squares (WCSS)**.

```
Inertie = Σ (pour k = 1 à K) Σ (pour xᵢ ∈ Cₖ) || xᵢ - μₖ ||²
```

où :

- C_k = cluster k
- μ_k = centroïde du cluster
- x_i = observation

Intuition

On veut que les points soient :

> **le plus proche possible de leur centroïde.**

9. Méthode Elbow — Choisir K

Une question importante :

> **Comment choisir le nombre de clusters ?**

Une méthode courante est la **méthode du coude (Elbow Method)**.

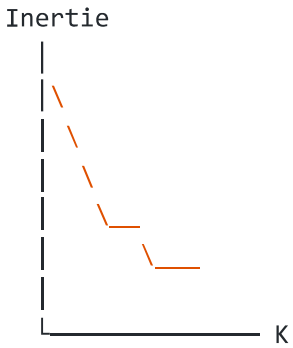
Principe

On entraîne K-Means avec plusieurs valeurs de K.

Pour chaque K, on récupère :

```
kmeans.inertia_
```

Puis on trace l'inertie en fonction de K.



On recherche le « **coude** » de la courbe.

Pourquoi ?

Augmenter `K` réduit presque toujours l'inertie.

Mais à partir d'un certain moment, ajouter un cluster supplémentaire apporte relativement peu d'amélioration.

C'est cette zone de ralentissement que l'on cherche à identifier.

> **Attention :** l'Elbow Method donne un indicateur, pas une vérité absolue. Il faut aussi regarder la silhouette, la visualisation et la cohérence métier.

🟢 10. Silhouette Score

Le **Silhouette Score** mesure notamment :

- la proximité d'une observation avec son propre cluster ;
- sa séparation par rapport aux autres clusters.

Le score est compris entre :

```
-1 ———————— 0 ———————— +1
```

Valeur	Interprétation
proche de `+1`	bonne séparation
proche de `0`	observation proche d'une frontière
négatif	possible mauvaise affectation

🟣 11. Clustering Hiérarchique

Le clustering hiérarchique construit progressivement une **hiérarchie de groupes**.

La représentation classique est le :

> **Dendrogramme**

Agglomerative Clustering

L'approche la plus courante est **bottom-up**.

Étape 1

Chaque observation commence comme son propre cluster.

A
B
C
D
E

Étape 2

Les observations les plus proches sont fusionnées.

AB
C
D
E

Étape 3

On continue les fusions.

AB
CD
E

Puis :

ABCD
E

Et finalement :

ABCDE

Linkage

Les méthodes principales sont :

- **Ward**
- **Complete**
- **Average**
- **Single**

Ward

La méthode Ward cherche à minimiser l'augmentation de la variance intra-cluster lors des fusions.

🌳 12. Dendrogramme

Le dendrogramme permet de visualiser les différentes fusions.

Il peut aider à choisir le nombre de clusters en observant les niveaux auxquels les groupes sont fusionnés.

🔴 13. DBSCAN

DBSCAN signifie :

> Density-Based Spatial Clustering of Applications with Noise

Contrairement à K-Means, DBSCAN se base principalement sur la **densité des points**.

Il cherche des zones où les observations sont fortement concentrées.

Paramètres principaux

`eps`

Définit le rayon utilisé pour rechercher les voisins.

`min_samples`

Nombre minimal de points nécessaires pour considérer une zone comme suffisamment dense.

📊 15. Évaluation du Clustering

Une difficulté du clustering est l'absence de `y`.

On ne peut donc pas utiliser directement les métriques classiques de classification comme :

- Accuracy
- Precision
- Recall
- F1-score

On utilise plutôt des métriques spécifiques.

Principales métriques

1. Inertie

Utilisée notamment avec K-Means.

2. Silhouette Score

Mesure la cohésion et la séparation des clusters.

3. Davies-Bouldin Index

Évalue la similarité entre les clusters.

4. Calinski-Harabasz Score

Compare la dispersion entre les clusters à la dispersion à l'intérieur des clusters.

⚠️ 28. Limites de K-Means

Il faut choisir K

Le nombre de clusters n'est pas automatiquement connu.

Sensibilité aux outliers

Quelques observations extrêmes peuvent déplacer les centroïdes.

Forme des clusters

K-Means fonctionne particulièrement bien lorsque les clusters sont relativement compacts et séparables.